

## 13. Escalabilidad de AWS Lambda

### Como escala Lambda

Lambda escala automaticamente sin configuracion. Cuando llegan multiples requests simultaneos, AWS crea instancias adicionales de la funcion en paralelo:

- 1 request = 1 instancia de Lambda
- 10 requests simultaneos = 10 instancias en paralelo
- 1000 requests simultaneos = 1000 instancias en paralelo

No hay servidores que levantar ni configuracion de auto-scaling. AWS lo hace automaticamente.

### Limites por defecto

| Limite                         | Valor                           | Configurable                     |
|--------------------------------|---------------------------------|----------------------------------|
| Concurrencia por cuenta/region | 1,000 instancias simultaneas    | Si, se puede pedir aumento a AWS |
| Burst inicial                  | 500-3000 (depende de la region) | No                               |
| Escalado despues del burst     | +500 instancias/minuto          | No                               |
| Timeout maximo                 | 15 minutos                      | Si (en el codigo CDK)            |
| Memoria                        | 128 MB - 10 GB                  | Si (en el codigo CDK)            |

### Donde se configura

En el stack CDK (lib/campanias-prototype-stack.ts), los parametros de cada Lambda:

[Diagrama - ver archivo PNG adjunto]

### Provisioned Concurrency (opcional, para produccion)

Si se requiere garantizar que siempre haya instancias calientes (sin cold start):

[Diagrama - ver archivo PNG adjunto]

Costo: aproximadamente \$0.015/hora por instancia reservada. Para el prototipo no es necesario.

### Configuracion del prototipo actual

| Aspecto                 | Valor actual                       |
|-------------------------|------------------------------------|
| Escalabilidad           | Automatica (0 a 1000 simultaneas)  |
| Configuracion necesaria | Ninguna                            |
| Costo cuando no se usa  | \$0 (pay-per-invocation)           |
| Cold start              | 200-500ms en la primera invocacion |
| Timeout                 | 30 segundos                        |
| Memoria                 | 256 MB                             |

## Cuando considerar ajustes

| Escenario                               | Accion                                        |
|-----------------------------------------|-----------------------------------------------|
| Mas de 1000 requests/segundo            | Solicitar aumento de limite a AWS Support     |
| Latencia crítica (< 100ms)              | Activar Provisioned Concurrency               |
| Procesamiento pesado (ML, ETL)          | Aumentar memoria (hasta 10 GB)                |
| Procesos largos (> 15 min)              | Usar Step Functions o ECS/Fargate en su lugar |
| Campañas masivas (100K+ notificaciones) | Usar SQS como buffer + multiples Lambdas cons |

## Relacion con otros servicios del prototipo

| Servicio                   | Escalabilidad                         |
|----------------------------|---------------------------------------|
| API Gateway                | Automatica (10,000 req/s por defecto) |
| DynamoDB (PAY_PER_REQUEST) | Automatica (sin limite practico)      |
| EventBridge                | Automatica (ilimitada)                |
| SQS                        | Automatica (ilimitada)                |

Todos los servicios del prototipo escalan automaticamente sin intervencion manual.